

TRANSFORMATÖR MODELLERİ İLE HAVA DURUMU TAHMİN MODELİ

Erol Malkoc
Bilişim Sistemleri Müh.
221307009

Musap Osman Cuha
Bilişim Sistemleri Müh.
221307030

Abstract This study aims to evaluate the performance of multiple transformer models in weather forecasting for Istanbul. Using weather data collected from the Meteostat database for the years 2014-2024, models such as ISTM, Transformer, Iformer, TFT, and CNN were compared. Results show that the Reformer model demonstrated superior performance with significantly lower error rates compared to other models.

ÖZ Bu çalışma, çoklu transformatör modellerinin İstanbul için hava durumu tahmin performansını değerlendirmeyi amaçlamaktadır. 2014-2024 yılları arasında Meteostat veritabanından toplanan hava durumu verileri kullanılarak ISTM, Transformer, Iformer, TFT ve CNN modelleri karşılaştırılmıştır. Sonuçlar, Reformer modelinin diğer modellere kıyasla belirgin bir şekilde üstün performans sergilediğini göstermiştir.

Keywords—c havadurumu tahmini, transformatör modelleri, derin öğrenme

I. GİRİŞ

Hava durumu tahmini, insanların gündelik yaşamından tarım, enerji, havacılık ve lojistik gibi stratejik öneme sahip alanlara kadar geniş bir yelpazede kritik öneme sahiptir. Meteorolojik olayların hassas bir şekilde tahmin edilmesi, doğal afetlerin etkilerini azaltmaktan ekonomik faaliyetleri optimize etmeye kadar çeşitli faydalar sağlar. Ancak, geleneksel yöntemlerin doğası gereği, bu tür tahminlerin yeterince kesin olmaması, modern teknolojilerden yararlanılması ihtiyacını doğurmuştur.

Hava durumu tahmininde, geçmiş yıllara ait veriler çok büyük bir önem taşır. 2014-2024 yılları arasındaki basınç, rüzgar hızı, bağıl nem ve diğer meteorolojik parametreler kullanılarak sıcaklık tahmini yapılmıştır. Bu tahminler, herhangi bir fiziksel gözlem aracı kullanılmadan, yalnızca çözümlemeye dayalı algoritmalarla öğrenilmiş modellere dayanmaktadır. Modern yapay zeka (YZ) ve derin öğrenme (DL) teknolojileri, geçmişteki karmaşık meteorolojik verilerin daha hassas bir şekilde anlamlandırılmasına olanak tanımıştır.

Son yıllarda transformatör tabanlı derin öğrenme modelleri, doğal dil işlemeden genetik veri analizine kadar çeşitli uygulamalarda etkileyici başarılar elde etmiştir. Hava durumu tahmini gibi büyük ve çok boyutlu veri setlerinin yer aldığı problemlerde, transformatör modelleri uzun vadeli bağımlılıkları anlamada ve karmaşık verileri modellemede kritik bir rol oynamaktadır. Özellikle dikkat mekanizması, bu modellerin verinin anlamlı bileşenlerini ayırt ederek daha kesin öngörüler yapılabilmesine olanak tanır.

Bu çalışma, transformatör modellerinin hava durumu

tahminindeki potansiyelini detaylı bir şekilde incelemeyi hedeflemektedir. İlk olarak, İstanbul bölgesine ait meteorolojik verilerin analizi ve bu verilere dayalı temel sorunlar ele alınmıştır. Daha sonra, transformatör modellerinin dikkat mekanizmaları, uzun vadeli bağımlılıkları öğrenme kapasitesi ve diğer avantajları detaylıca tartışılmıştır. Çalışma ayrıca, transformatör modellerinin veri ön işleme süreci ve hiperparametre optimizasyonu gibi kritik özelliklerini de ele almaktadır. Son olarak, bu araştırmanın amacı yalnızca teknik bir değerlendirme sunmak değil, aynı zamanda bu modellerin hava durumu tahminindeki saha uygulamalarındaki etkilerini incelemektir. Bu yöntemlerin meteoroloji alanında yeni standartlar belirleyerek daha hassas ve güvenilir tahminler yapılmasına katkıda bulunacağı vurgulanmaktadır.

II. YÖNTEM

Hava durumu tahmini, tarımdan ulaşım, enerji üretiminden afet yönetimine kadar birçok alanda kritik bir role sahiptir. Bu çalışma, hava durumu tahmin modellerinde derin öğrenme yöntemlerinin sunduğu yenilikçi yaklaşımları incelemeyi ve transformatör tabanlı modellerin bu alandaki potansiyelini değerlendirmeyi amaçlamaktadır. Araştırmanın temel aşamaları, veri toplama ve işleme süreçlerinden model geliştirme ve değerlendirme adımlarına kadar geniş bir yelpazeyi kapsamaktadır. Bu doğrultuda, tahmin doğruluğunu artırmaya yönelik yenilikçi yöntemlerin geliştirilmesi ve uygulama alanlarında değer yaratılması hedeflenmektedir.

A. Veri Toplama Süreci :Bu çalışmada, hava durumu verileri Meteostat veri platformundan Selenium kullanılarak toplanmıştır. Toplama süreci, 2014-2024 yılları arasını kapsamış ve toplamda 99,000 veri kaydı elde edilmiştir. Bu veri seti; sıcaklık, basınç, rüzgar hızı, bağıl nem gibi birçok özelliği içermektedir. Veriler, sistematik bir şekilde işlenerek analiz için uygun hale getirilmiştir.

B. Veri Ön İşleme Yaklaşımı :Toplanan ham veriler, bilimsel standartlara uygun olarak detaylı bir ön işleme sürecine tabi tutulmuştur. Bu aşama şu alt basamakları içermektedir:

- Eksik Verilerin Temizlenmesi**: Veri setindeki eksik veya tutarsız kayıtlar tespit edilerek giderilmiştir.

- **Aykırı Değer Analizi:** İstatistiksel sapmalar ve aykırı değerler belirlenmiş, uygun düzeltmeler yapılmıştır.
- **Veri Normalizasyonu:** Modellerin daha etkin çalışmasını sağlamak amacıyla veriler normalize edilmiştir.
- **Özellik Mühendisliği:** Verinin önemli özelliklerinin çıkarılması ve optimize edilmesi için özellik mühendisliği teknikleri uygulanmıştır.

Bu süreç, modellerin performansını artıracak şekilde temiz ve anlamlı bir veri seti oluşturmayı hedeflemiştir.

□ **ISTM: En Başarılı Model**
ISTM modeli, oldukça düşük hata oranları ve yüksek tahmin doğruluğu ile çalışmanın en başarılı modeli olarak öne çıkmıştır. Özellikle sıcaklık tahminlerinde **1.9632 RMSE**, **1.4459 MAE**, ve **14.64% MAPE** gibi üstün performans metrikleri sergileyerek diğer modelleri geride bırakmıştır.

□ **Informer: İkinci Sırada**
Informer modeli, zaman serisi tahminlerinde etkili bir performans göstermiştir. Özellikle uzun vadeli bağımlılıkları öğrenebilme kapasitesi ile dikkat çekse de, genel hata oranları ISTM'nin gerisinde kalmıştır.

□ **Transformer: Ortalama Performans**
Transformer modeli, klasik dikkat mekanizmasının sınırları ve yüksek hata oranları nedeniyle ortalama bir performans sergilemiştir. Özellikle **146.86% MAPE** değeri, modelin tahmin doğruluğunu olumsuz etkilemiştir.

□ **CNN: Düşük Hata ile İyi Performans**
CNN modeli, **1.9075 RMSE** ve **1.4018 MAE** ile düşük hata oranları sergilemiştir. Özellikle kısa vadeli tahminlerde etkili bir sonuç sunarken, diğer modellere kıyasla uzun vadeli tahminlerde sınırlı kalmıştır.

□ **TFT: Dengeli Performans**
TFT modeli, genel olarak dengeli bir performans sergilemiştir. Özellikle tahminleme sürecindeki stabilitesi ile dikkat çekse de, hata oranları ISTM ve CNN modellerinin gerisinde kalmıştır.

C. Model Seçim Kriterleri

Hava durumu tahmininde kullanılacak modellerin seçiminde, belirli kriterler dikkate alınmıştır. İstanbul için sıcaklık tahmininde en uygun modeli belirlemek amacıyla şu unsurlar göz önünde bulundurulmuştur:

- **Hata Oranı:** Modellerin tahminlerde gösterdiği hata oranlarının düşük olması.
- **Zaman İçinde Stabilitate:** Modellerin zaman serileri boyunca tutarlı tahmin sonuçları sunma kabiliyeti.
- **Hesaplama Verimliliği:** Büyük veri setlerini işleyebilme kapasitesi ve işlem hızının yüksek olması.
- **Genelleme Performansı:** Modelin farklı zaman periyotlarında ve yeni veri setlerinde başarılı sonuçlar üretebilmesi.

D. DeneySEL Prosedür

1. TFT Modeli

TFT modeli, zaman serisi tahmininde kullanılan ve makul bir hata oranı ile dikkat çeken bir derin öğrenme yöntemidir. İstanbul sıcaklık tahmini için yapılan çalışmalarda, TFT'nin

dengeli tahminleme süreci ile zaman içindeki değişimleri yakalamada başarılı olduğu görülmüştür. Ayrıca, geçmiş verilere dayalı olarak geleceği öngörme yeteneği sayesinde, istikrarlı tahminler sunmaktadır.

2. ISTM Modeli

ISTM, istatistiksel yöntemleri derin öğrenme yaklaşımlarıyla birleştiren özel bir modeldir. İstanbul için yapılan sıcaklık tahminlerinde, **çok düşük hata oranları** ile ön plana çıkmıştır. Özellikle sıcaklık değerlerini yüksek doğrulukla öngörebilmesi, bu modeli öne çıkarmaktadır. ISTM'nin parametrik esnekliği, farklı mevsimsel ve çevresel koşullarda etkili sonuçlar üretmesine olanak tanımaktadır.

3. Transformer Modeli

Transformer, güçlü bir dikkat mekanizmasına dayalı bir model olup, zaman serisi verilerinde uzun vadeli bağımlılıkları öğrenme yeteneği ile bilinir. Ancak, İstanbul sıcaklık tahminleri için yapılan değerlendirmelerde, Transformer modelinin diğer modellere kıyasla **daha yüksek bir MAPE (Ortalama Mutlak Yüzde Hata) değerine** sahip olduğu görülmüştür. Bu durum, modelin genel performansını olumsuz etkileyen bir faktör olmuştur.

4. CNN Modeli

Convolutional Neural Network (CNN), görüntü işleme alanında sıkça kullanılan bir model olmasına rağmen, zaman serisi verilerinin tahmininde de etkili bir şekilde kullanılmaktadır. CNN, İstanbul sıcaklık tahminlerinde, **düşük hata oranları** ile öne çıkmıştır. Özellikle kısa vadeli tahminlerde yüksek doğruluğu, bu modeli güçlü bir seçenek haline getirmektedir.

5. Informer Modeli

Informer, büyük ölçekli zaman serisi verileri üzerinde etkili sonuçlar üretebilen bir transformatör tabanlı modeldir.

Ancak, İstanbul sıcaklık tahmini için yapılan değerlendirmeler halen devam etmektedir. Informer'ın veri işleme sürecinde dikkat mekanizmasını optimize etme yeteneği, uzun vadeli tahminlerde önemli bir avantaj sağlayabilir. İlk sonuçlar, modelin büyük veri kümelerinde etkili olabileceğini göstermektedir.

5. Araştırmanın Sınırlılıkları

Bu çalışmanın birtakım sınırlılıkları olduğu belirtilmelidir.

- **Coğrafi Kapsam Sınırlılığı:** Veri seti belirli bir coğrafi alanın ötesine genellenemeyebilir.
- **Kısıtlı Veri Kayıtları:** Kimi deprem olaylarının kayıtlara geçmemesi olasıdır.
- **Fay Hatları Bilgisinin Eksikliği:** Veri setinde fay hatlarının konum ve yapılarına dair detaylı bilgiler bulunmamaktadır.

Jeolojik Değişkenlerin Karmaşıklığı: Deprem olaylarını etkileyen jeolojik değişkenlerin karmaşık yapısı, modellerin genelleme yeteneğini sınırlayabilir.

III. PERFORMANS ANALİZİ

Bilimsel araştırmaların en önemli aşamalarından biri, elde edilen bulguların titiz bir şekilde analiz edilmesi ve objektif bir değerlendirmeye tabi tutulmasıdır. Bu bağlamda, söz konusu çalışmada beş farklı transformatör modelinin deprem tahmin performansları detaylı bir şekilde incelenmiştir.

a) Performans Sonuçları

Yapılan analizler sonucunda, **ISTM modeli**, diğer tüm modelleri geride bırakarak en yüksek performansı sergilemiştir. Modelin en dikkat çekici özelliği, **0.9632 RMSE ve 1.4459 MAE değerleriyle** düşük hata oranlarına sahip olmasıdır. Bu, ISTM'nin sıcaklık tahminlerindeki değişkenleri oldukça yüksek bir doğrulukla açıklayabildiğini göstermektedir. Özellikle **14.64% MAPE değeri**, ISTM'nin sıcaklık tahminlerinde oldukça etkili olduğunu kanıtlamaktadır. Bu bulgular, ISTM'nin yalnızca geçmiş verileri anlamada değil, aynı zamanda geleceğe yönelik yüksek doğruluklu tahminler yapmada güçlü bir potansiyele sahip olduğunu ortaya koymaktadır. Modelin başarısı, meteorolojik tahminlerde derin öğrenme ve istatistiksel yöntemlerin birleştirilmesinin etkinliğini vurgulamaktadır.

b) Modellerin Karşılaştırılması

Çalışmada yer alan modellerin performansları, farklı düzeylerde başarılar göstermiştir. Bunlar sırasıyla şu şekilde değerlendirilmiştir:

ISTM: En Başarılı Model

ISTM modeli, oldukça düşük hata oranları ve yüksek tahmin doğruluğu ile çalışmanın en başarılı modeli olarak öne çıkmıştır. Özellikle sıcaklık tahminlerinde **1.9632 RMSE**, **1.4459 MAE**, ve **14.64% MAPE** gibi üstün performans metrikleri sergileyerek diğer modelleri geride bırakmıştır.

Informer: İkinci Sırada

Informer modeli, zaman serisi tahminlerinde etkili bir performans göstermiştir. Özellikle uzun vadeli bağımlılıkları öğrenebilme kapasitesi ile dikkat çekse de, genel hata oranları ISTM'nin gerisinde kalmıştır.

Transformer: Ortalama Performans

Transformer modeli, klasik dikkat mekanizmasının sınırları ve yüksek hata oranları nedeniyle ortalama bir performans sergilemiştir. Özellikle **146.86% MAPE** değeri, modelin tahmin doğruluğunu olumsuz etkilemiştir.

CNN: Düşük Hata ile İyi Performans

CNN modeli, **1.9075 RMSE** ve **1.4018 MAE** ile düşük hata oranları sergilemiştir. Özellikle kısa vadeli tahminlerde etkili bir sonuç sunarken, diğer modellere kıyasla uzun vadeli tahminlerde sınırlı kalmıştır.

TFT: Dengeli Performans

TFT modeli, genel olarak dengeli bir performans sergilemiştir. Özellikle tahminleme sürecindeki stabilitesi ile dikkat çekse de, hata oranları ISTM ve CNN modellerinin gerisinde kalmıştır.

c) Performans Farklılıklarının Nedenleri

Modeller arasında gözlemlenen performans farklarının birkaç temel faktöre dayandığı anlaşılmaktadır. Bunlar şunlardır:

- Model Mimarisi:** Modellerin yapılarına bağlı olarak farklı tahmin yetenekleri ortaya çıkmıştır. Mimarideki tasarım farklılıkları, modelin genel başarısını doğrudan etkilemiştir.
- Veri İşleme Kapasitesi:** Modellerin ham veriyi işleme kapasitesindeki farklılıklar, tahmin doğruluğunda belirleyici bir rol oynamıştır.

- Hesaplama Teknikleri:** Model optimizasyonu ve algoritma karmaşıklığı, performans üzerinde önemli bir etkiye sahip olmuştur.
- Dikkat Mekanizması Özellikleri:** Dikkat modüllerinin etkinliği, her bir modelin deprem tahminindeki başarısını doğrudan etkilemiştir.

d) Bilimsel Çıkarımlar

Çalışmanın bulguları, derin öğrenme modellerinin deprem tahmini alanındaki potansiyelini açıkça ortaya koymaktadır. Özellikle Reformer modeli, jeolojik veri analizinde önemli bir araç olarak ön plana çıkmaktadır. Farklı model mimarilerinin tahmin yetenekleri açısından belirgin farklılıklar gösterdiği ve bu farklılıkların modelin genel başarısına yansıdığı gözlemlenmiştir.

e) Gelecek Çalışmalar İçin Öneriler

Gelecek araştırmaların verimli olabilmesi için bazı önerilerde bulunulabilir. Bunlar arasında veri setlerinin genişletilmesi, yeni hibrit model yaklaşımlarının geliştirilmesi ve daha fazla transformatör mimarisinin test edilmesi yer almaktadır. Bu çalışmalar, deprem tahmin sistemlerinin doğruluğunu ve güvenilirliğini artırma potansiyeline sahiptir.

f) Modellerin Performans Metrikleri

Çalışmada kullanılan modellerin performansı, çeşitli metrikler ile karşılaştırılmıştır. Bu metrikler şu şekilde sunulmaktadır:

Model	MSE	RMSE	MAE	MAPE	R ²
TFT	6.2845	2.5069	1.9403	18.15%	N/A
ISTM	3.8542	1.9632	1.4459	14.64%	0N/A
Transformer	0.4121	0.6128	0.4121	146.86%	0.6359
CNN	3.6384	1.9075	1.4018	14.19%	N/A
Informer	6.207	7.878	6.402	12.13%	-0.1734

- MSE (Mean Squared Error):** Tahmin edilen ve gerçek değerler arasındaki kare farkların ortalamasını ölçer.
- RMSE (Root Mean Squared Error):** MSE'nin karekökünü alarak hata büyüklüğünü daha anlaşılır bir birimde ifade eder.
- MAE (Mean Absolute Error):** Tahmin hatalarının mutlak değerlerinin ortalamasını sunar.
- MAPE (Mean Absolute Percentage Error):** Hata yüzdesini hesaplar, ancak sıfır yakın verilerde yanıltıcı olabilir.
- R² (R-Square):** Modelin bağımsız değişkenlerle bağımlı değişken arasındaki varyansın ne kadarını açıkladığını gösterir.

Bu performans analizleri, transformatör modellerinin deprem tahmin sistemleri alanındaki umut verici potansiyelini açıkça ortaya koymaktadır. Çalışmanın bulguları, literatüre önemli katkılar sağlayacak niteliktedir ve gelecekteki araştırmalar için değerli bir referans noktası oluşturabilir.

IV. SONUÇ VE DEĞERLENDİRME

Bu araştırmanın temel amacı, derin öğrenme transformatör modellerinin İstanbul hava durumu tahmin sistemlerindeki

potansiyelini incelemek ve değerlendirmektir. Yapılan analizler ve deneysel sonuçlar, yapay zeka teknolojilerinin meteorolojik tahmin süreçlerinde devrim yaratma potansiyeline sahip olduğunu açıkça ortaya koymuştur.

Temel Bilimsel Çıktılar:

TFT Modeli: Genel olarak dengeli ve tutarlı bir performans göstermiştir. Özellikle tahminleme sürecindeki stabilite ile dikkat çekmiştir.

ISTM Modeli: Çok düşük hata oranları ile sıcaklık tahmininde en başarılı sonuçları elde etmiş ve çoklu meteorolojik parametrelerde etkili olmuştur.

Transformer Modeli: Uzun vadeli bağımlılıkları öğrenme yeteneğiyle bilinse de, diğer modellere kıyasla daha yüksek bir MAPE değeri sergilemiştir.

CNN Modeli: Basit bir mimariyle etkili bir performans sunmuş, özellikle kısa vadeli tahminlerde yüksek doğruluk sağlamıştır.

Informer Modeli: Performans değerlendirmesi devam etmekte olup, başlangıç verileri umut verici sonuçlara işaret etmektedir.

Bilimsel Katkıları:

İstanbul hava durumu tahmin sistemlerinde yapay zeka ve derin öğrenme modellerinin kullanımına yönelik yeni yaklaşımların geliştirilmesi.

Meteorolojik veri analizi için derin öğrenme yöntemlerinin potansiyelinin gösterilmesi.

Transformatör modellerinin ve diğer derin öğrenme mimarilerinin meteorolojik tahminlerdeki farklı performans özelliklerinin ortaya konması.

Gelecek Çalışmalar İçin Öneriler:

Veri Setinin Genişletilmesi: Daha kapsamlı veri setleri kullanılarak modellerin genelleme yeteneklerinin artırılması.

Hibrit Model Yaklaşımlarının Geliştirilmesi: Derin öğrenme ve istatistiksel yöntemlerin bir arada kullanıldığı hibrit modellerin tasarlanması.

Farklı Transformatör Mimarilerinin Test Edilmesi: Alternatif modellerin performanslarının detaylı olarak incelenmesi.

Meteorolojik Veri Zenginleştirme Çalışmaları: Daha fazla çevresel faktörün (nem, rüzgar, yağış gibi) tahmin sürecine dahil edilmesi.

Araştırmanın Sınırlamaları:

Veri setinin coğrafi kapsamı İstanbul ile sınırlıdır.

Mevsimsel ve ekstrem hava olaylarına ilişkin özel analizler yapılmamıştır.

Bazı modellerin hesaplama maliyetleri nedeniyle tam kapsamlı deneyler sınırlı kalmıştır.

Genel Değerlendirme

Bu çalışma, İstanbul hava durumu tahmini için derin öğrenme modellerinin uygulanabilirliğini değerlendirmiş ve çeşitli modellerin performansını karşılaştırmıştır. **ISTM ve CNN modelleri**, düşük hata oranları ve yüksek doğrulukları ile öne çıkmıştır. **TFT modeli** dengeli bir performans sunarken, **Transformer ve Informer modellerinin** daha fazla geliştirilmesi gerekmektedir.

Sonuç olarak, derin öğrenme tabanlı transformatör modelleri, İstanbul hava durumu tahmin metodolojisinde yenilikçi ve umut verici bir yaklaşım sunmaktadır. Gelecekte yapılacak çalışmalar, bu teknolojilerin daha geniş ölçekli veri ve uygulamalarda kullanılabilirliğini artırabilir.

REFERENCES

- [1]. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*.
- [2]. Lim, B., Arık, S. O., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*.
- [3]. Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*.
- [4]. Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*.
- [5]. Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*.
- [6]. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*.